

Machine Learning

Introducción

Dr. Mauricio Toledo-Acosta

Table of Contents

1 Introducción

- Inteligencia Artificial
- Machine Learning

2 Componentes del Machine Learning

- Datos
- Features y Preprocesamiento
- Algoritmos
- Validación
- Métricas de Rendimiento

¿Qué es la Inteligencia Artificial?

¿Qué es el Aprendizaje Automático?

Referencia

¿Qué es la Inteligencia Artificial?


Definición práctica

La **Inteligencia Artificial (IA)** son sistemas que imitan capacidades humanas como:


- Aprender de ejemplos (como recomendar videos)
- Interpretar datos (reconocer rostros en fotos)
- Tomar decisiones (asistentes virtuales)

Tipos de IA

- Que *piensan* como humanos
asistentes predictivos, chatbots
- Que *actúan* como humanos
robots




Algunas áreas de la IA



doi:10.13140/RG.2.2.23097.80485

Evolución de la IA

Artificial Intelligence Development History Timeline



Get these slides & icons at www.infoDiagram.com

<https://qbi.uq.edu.au/brain/intelligent-machines/history-artificial-intelligence>

¿Qué es el Machine Learning?

Machine Learning (Aprendizaje Automático)

El **Machine Learning** es una rama de la inteligencia artificial, cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan con el objetivo de resolver ciertas tareas.

¿Qué significa aprender?


Se dice que un agente aprende cuando su desempeño mejora con la experiencia y mediante el uso de datos; es decir, cuando la habilidad no estaba presente en su diseño intrínseco.

En el aprendizaje automático un algoritmo observa datos, construye un modelo basado en esos datos y utiliza ese modelo a la vez como una hipótesis acerca del mundo y una *pieza de software* que puede realizar predicciones.

Paradigmas computacionales

A screenshot of a web browser showing a Twitter account creation page. The page is titled 'Etapa 1 de 5' and 'Criar sua conta'. It has input fields for 'Nome' (with 'User' entered) and 'E-mail' (with 'user@example.com.au' entered). There are buttons for 'Avançar', 'Entrar', and 'Inscrever-se'. A message below the email field says 'Insira um e-mail válido.' and there is a link 'Usar o telefone'.

Programación Tradicional



Machine Learning

Dos paradigmas complementarios para resolver problemas computacionales:

Programar un robot vs Enseñar a un niño.

Considera los siguientes problemas:

- ① Calcular la integral $\int_0^2 x^2 dx$
- ② Determina el sentimiento (ejemplos).
- ③ Determina el dígito.
- ④ Determina si una cadena de texto es una dirección de correo válida
- ⑤ Determina el precio de una casa en venta
- ⑥ Determinar si un número es primo

Machine Learning vs Algoritmos tradicionales

Un **algoritmo tradicional** toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Machine Learning vs Algoritmos tradicionales

Un **algoritmo tradicional** toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Por el contrario, un **algoritmo de aprendizaje automático** toma una entrada y una salida y aprende una lógica que puede utilizarse para trabajar con nuevas entradas y obtener una salida. Esta lógica se obtiene a partir de los patrones presentes en los datos.

Machine Learning vs Algoritmos tradicionales


Un **algoritmo tradicional** toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Por el contrario, un **algoritmo de aprendizaje automático** toma una entrada y una salida y aprende una lógica que puede utilizarse para trabajar con nuevas entradas y obtener una salida. Esta lógica se obtiene a partir de los patrones presentes en los datos.

Traditional Programs: Define algo/logic to compute output



Machine Learning: Learn model/logic from data



<https://www.linkedin.com/pulse/machine-learning-vs-traditional-software-development-ml4devs-gupta>

Fases de un programa de Machine Learning

Los programas de aprendizaje automático tienen dos fases distintas:

- 1 **Entrenamiento:** Las entradas y la salida esperada se utilizan para entrenar y probar varios modelos. Se selecciona el modelo más adecuado. *Entrenar* quiere decir determinar los parámetros adecuados del modelo para producir la salida esperada, a partir de las entradas.
- 2 **Inferencia o predicción:** El modelo se aplica a nuevos datos de entrada para predecir nuevas salidas, las cuales pueden compararse con las salidas reales.

¿Por qué necesitamos el Machine Learning?

En el enfoque clásico, antes del ML, se usaban algoritmos que procesaban los datos con base en reglas lógicas (if, else, ...).

Ejemplo: La detección de correo spam.

¿Por qué necesitamos el Machine Learning?

En el enfoque clásico, antes del ML, se usaban algoritmos que procesaban los datos con base en reglas lógicas (`if`, `else`, ...).


- La lógica para tomar las decisiones es específica de acuerdo al dominio y a la tarea. Pequeños cambios en la tarea requieren rediseñar el sistema.
- El diseño de las reglas requiere un entendimiento profundo del dominio por parte de un experto. Estas reglas pueden ser muy complicadas.

Ejemplo: La detección de correo spam.

Los tres paradigmas del Machine Learning

- ➊ Aprendizaje supervisado (Supervised Learning). El modelo aprende de ejemplos etiquetados para hacer predicciones de nuevos datos.
- ➋ Aprendizaje no supervisado (Unsupervised Learning). El modelo encuentra patrones o estructuras intrínsecas en los datos sin etiquetar.
- ➌ Aprendizaje por refuerzo (Reinforcement Learning). El modelo aprende las acciones a tomar en un entorno para maximizar una noción de recompensa acumulativa.

Los tres paradigmas del Machine Learning




Machine Learning en Acción

- **Regresión:** Predecir precios de casas, predecir el consumo de energía eléctrica, predecir el precio de acciones.
- **Clasificación:** Diagnóstico médico, Identificación de rostros en fotos, identificación de spam, identificación de contenido ofensivo.
- **Clustering:** Segmentación de clientes, identificación de tópicos en documentos.


Aprendizaje Supervisado

- 1 Regresión.
- 2 Clasificación.



Regression


versus




Classification

Aprendizaje No Supervisado

Clustering




Reducción de dimensionalidad



Aprendizaje por Refuerzo

- 1 Navegación en vehículos autónomos.
- 2 Texto predictivo.
- 3 Sistemas de recomendación.
- 4 Videojuegos.
- 5 Conservación y eficiencia energética.
- 6 Mejoramiento de los LLMs.

Timeline de los algoritmos de Machine Learning



<http://beamlab.org/deeplearning/2017/>

Table of Contents

- 1 Introducción
 - Inteligencia Artificial
 - Machine Learning
- 2 Componentes del Machine Learning
 - Datos
 - Features y Preprocesamiento
 - Algoritmos
 - Validación
 - Métricas de Rendimiento

Componentes del Machine Learning


Datos



Variables
(features)



Algoritmos




Métricas

	NO	yes
NO	True negative	False positive
YES	False negative	True positive

Ejemplo: Desde datos de correos hasta clasificar spam.

Workflow del Machine Learning



Datos



Los datos pueden tener formas diferentes:

- Tablas estructuradas
- Imágenes
- Texto
- Archivos de audio
- Archivos de video
- Series de tiempo
- Grafos

A un conjunto de datos, se le llama **dataset** (no es lo mismo que *base de datos*). Fuentes de datasets:

- Kaggle
- Scikit-Learn.
- HuggingFace

Algunos datasets famosos



- MNIST
- Iris Flowers Dataset.
- Boston House Price Dataset.
- Wine Quality Dataset.
- Pima Indians Diabetes Dataset.
- 20newsgroups.
- Titanic

Los **datos** son muy importantes de la ciencia de **datos**.

Features

Los datasets **son** tablas donde cada fila representa una entidad y cada columna una característica de esa entidad. Es decir, cada entidad esta representada por un conjunto de variables (features, características).

Hay varios tipos de variables:

- Numéricas
 - Continuas: temperatura, longitud.
 - Discretas: número de habitaciones, habitantes.
- Categóricas
 - Ordinales: escalas numéricas (grado de satisfacción, nivel educativo).
 - Nominales: representan clases (género, modelo).

Las ordinales mantienen un orden lógico, las nominales son categorías sin jerarquía.

Ejemplo

Preprocesamiento

En cualquier proceso de Machine Learning, el **preprocesamiento** es el paso en el que los datos se **limpian**, **transforman** y/o **codifican** para llevarlos a un estado tal que ahora la máquina pueda analizarlos de *mejor forma*.

Preprocesamiento

En cualquier proceso de Machine Learning, el **preprocesamiento** es el paso en el que los datos se **limpian**, **transforman** y/o **codifican** para llevarlos a un estado tal que ahora la máquina pueda analizarlos de *mejor forma*.

Estos son algunos de los tipos de problemas básicos así como las técnicas de preprocesamiento a la que pertenecen:

- ¿Cómo limpio los datos? Limpieza de datos.
- ¿Cómo unifico y escalo los datos? Normalización de datos.
- ¿Cómo proporciono datos precisos? Transformación de datos.
- ¿Cómo manejo los datos faltantes? Imputación de datos perdidos.
- ¿Cómo incorporo y ajusto datos? Integración de datos.
- ¿Cómo detecto y manejo el ruido? Análisis del ruido.

Escalamiento MinMax

Definición

Escala los datos a un rango específico (por defecto $[0, 1]$).


$$x_{\text{scaled}} = \frac{x - \min(X)}{\max(X) - \min(X)}$$

Valores originales	Valores escalados
2	0
5	0.375
10	1


MinMaxScaler en scikit-learn

Escalamiento MinMax

Datos originales



Preprocesamiento



Escalamiento z-score

Definición

Estandariza los datos restando la media (μ) y dividiendo por la desviación estándar (σ).

$$x_{\text{scaled}} = \frac{x - \mu}{\sigma}$$


$\mu = 5.67$, $\sigma = 3.06$:

Valores originales	Valores escalados
2	-1.20
5	-0.22
10	1.41


StandardScaler en scikit-learn

Escalamiento z-score

Datos originales



Preprocesamiento



<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>

Escalamiento L_1 o L_2

Definición

Transforma cada **fila** o **columna** para que la suma de sus valores absolutos sea 1.

$$x_{\text{norm}} = \frac{x_i}{\left(\sum_{j=1}^n |x_j|^p\right)^{\frac{1}{p}}}$$


con $p = 1$ o $p = 2$.

Original	Normalizado (filas)	Normalizado (columnas)
1, 2, 3	0.17, 0.33, 0.50	0.25, 0.33, 0.43
4, 0, 1	0.80, 0.00, 0.20	1.00, 0.00, 0.14


Normalización en scikit-learn

Escalamiento L_1 o L_2

Escalamiento L_1



Escalamiento L_2



Este escalamiento es útil cuando se trata de representaciones vectoriales (*embeddings*) de texto, imágenes, etc.

Imputación

Definición

Rellena valores faltantes usando estrategias la media, mediana o moda de la fila (o columna).

$$\text{Media} = \frac{1}{n} \sum_{i=1}^n x_i$$

También se puede rellenar con valores predefinidos.

Original	Imputado (media)
1	1
NaN	3.33
4	3
5	5

Selección de Features: SelectKBest

Definición

Selecciona las k features con mayor puntuación según test estadístico. Selecciona las k características más relevantes según qué tan bien separan los grupos de tus datos.


Imagina que quieres distinguir entre perros y gatos

- Característica 1: Número de bigotes (buen discriminador)
- Característica 2: Peso
- Característica 3: Color del collar (mal discriminador)


Característica	Puntaje
Bigotes	22.1
Peso	15.2
Color collar	3.8

Selección de Features: SelectKBest

Datos originales



Preprocesamiento



https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectKBest.html

Selección de Features: Variance Threshold

Definición


Elimina features con varianza menor a un umbral predefinido.

$$\text{Var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Feature	Varianza
X1	0.05
X2	0.15
X3	0.01

VarianceThreshold en scikit-learn

Selección de Features: Variance Threshold



OneHotEncoding

Definición

Convierte variables categorías en vectores binarios. Genera nuevas variables categóricas que sólo pueden tomar valores 0 o 1.

Modelo	Color	Precio
Sedán	Rojo	\$25K
SUV	Azul	\$32K
Hatchback	Verde	\$18K
Sedán	Verde	\$22K

Modelo	R	A	V	Precio
Sedán	1	0	0	\$25K
SUV	0	1	0	\$32K
Hatchback	0	0	1	\$18K
Sedán	0	0	1	\$22K

OneHotEncoder en scikit-learn

Binning

Definición

Discretiza variables continuas en intervalos.

Edad	[0-20)	[20-40)	[40-60]
12	1	0	0
25	0	1	0
45	0	0	1
18	1	0	0
60	0	0	1
8	1	0	0

Es útil para reducir el ruido, manejar outliers. En algoritmos sensibles a relaciones continuas puede introducir problemas en el rendimiento.

KBinsDiscretizer en scikit-learn

Métodos Clave en Preprocesamiento

`fit()`

- **Aprende** parámetros del transformador
- Ejemplo: Calcula media/desviación para StandardScaler
- Nunca modifica los datos

Métodos Clave en Preprocesamiento

`transform()`

- **Aplica** la transformación usando parámetros aprendidos
- Requiere ejecutar `fit()` primero
- Ejemplo: Estandariza datos con μ y σ calculados


Métodos Clave en Preprocesamiento

`fit_transform()`

- **Aprende y aplica** en un solo paso
- Útil para datos de entrenamiento
- Evita data leakage (contaminación)

`fit` = aprender, `transform` = aplicar, `fit_transform` = aprender + aplicar

Workflow del Machine Learning: Algoritmos



Algoritmos

Un **algoritmo de Machine Learning** es la técnica que permite a una computadora aprender a partir de datos y tomar decisiones o hacer predicciones basadas en esa información.

Algoritmos

Un **algoritmo de Machine Learning** es la técnica que permite a una computadora aprender a partir de datos y tomar decisiones o hacer predicciones basadas en esa información.

Existen varios tipos de algoritmos de Machine learning, dependiendo del tipo de tarea que buscar modelar:

- Aprendizaje supervisado.
- Aprendizaje no supervisado.
- Aprendizaje por refuerzo.

Algoritmos



Cross Validation

Validación Cruzada

La validación cruzada es una técnica de validación de modelos para evaluar cómo se generalizarán los resultados de un análisis estadístico a un conjunto de datos independiente. La validación cruzada es un método de remuestreo que utiliza diferentes partes de los datos para probar y entrenar un modelo en diferentes iteraciones.


Es necesario tener una validación de la estabilidad de cualquier modelo de Machine Learning. Es decir, ¿qué tan bien podemos esperar que sea su rendimiento en datos que no ha visto?

Tecnicas de validación

- **Validación:** Evaluación del desempeño del modelo en los datos de entrenamiento.


Técnicas de validación

- **Validación:** Evaluación del desempeño del modelo en los datos de entrenamiento.
- **Conjunto de prueba:** Reservar una parte del conjunto de datos para ser usada como conjunto de prueba.




Técnicas de validación

- **K-Fold Cross Validation:** Los datos se dividen en k subconjuntos, una de las partes se usa como conjunto de prueba y las demás como entrenamiento. Se repite este método k veces, de forma que cada vez, uno de los k subconjuntos se utiliza como conjunto de prueba y los otros $k - 1$ subconjuntos, como conjunto de entrenamiento. La estimación del error se promedia sobre las k pruebas para obtener la eficacia total de nuestro modelo.




Técnicas de validación

- **Stratified K-Fold Cross Validation:** Variación de la validación cruzada K-fold normal, en lugar de que las divisiones sean completamente aleatorias, la proporción entre las clases objetivo es la misma en cada uno de los k subconjuntos que en el conjunto de datos completo.



Workflow del Machine Learning: Métricas de rendimiento



Métricas de desempeño

Las **métricas de desempeño** dan cuenta del desempeño del modelo entrenado. Estas funciones varían de acuerdo al tipo de tarea, **suelen ser funciones fácilmente interpretables** (porcentajes, conteos, diferencias, etc.).

- Regresión: MSE, MAE.
- Clasificación: Accuracy, precision, recall, F1-score, ROC-AUC.
- Clustering: AMI, MI, silhouette score.
- Tareas de NLP: Preplexity, entropy, coherence.
- ...

Métricas de desempeño: Ejemplo de clasificación

Hello Friends! We hope you had a pleasant week. Last weeks trivia questions was: What do these 3 films have in common: One Crazy Summer, Whispers in the Dark, Moby Dick? Answer: Nantucket Island	?
IMPORTANT INFORMATION: The new domain names are finally available to the general public at discount prices. Now you can register one of the exciting new .BIZ or .INFO domain names, as well as the original .COM and .NET names for just \$14.95. These brand new domain extensions were recently approved by ICANN and have the same rights as the original .COM and .NET domain names. The biggest benefit is of-course that the .BIZ and .INFO domain names are currently more available. i.e. it will be much easier to register an attractive and easy-to-remember domain name for the same price. Visit: http://www.affordable-domains.com today for more info.	?
If you have an internal zip drive (not sure about external) and you bios supports using a zip as floppy drive, you could use a bootable zip disk with all the relevant dos utils.	?

Métricas de desempeño: Ejemplo de clasificación

Hello Friends! We hope you had a pleasant week. Last weeks trivia questions was: What do these 3 films have in common: One Crazy Summer, Whispers in the Dark, Moby Dick? Answer: Nantucket Island	No Spam
IMPORTANT INFORMATION: The new domain names are finally available to the general public at discount prices. Now you can register one of the exciting new .BIZ or .INFO domain names, as well as the original .COM and .NET names for just \$14.95. These brand new domain extensions were recently approved by ICANN and have the same rights as the original .COM and .NET domain names. The biggest benefit is of-course that the .BIZ and .INFO domain names are currently more available. i.e. it will be much easier to register an attractive and easy-to-remember domain name for the same price. Visit: http://www.affordable-domains.com today for more info.	Spam
If you have an internal zip drive (not sure about external) and you bios supports using a zip as floppy drive, you could use a bootable zip disk with all the relevant dos utils.	No Spam

Accuracy (Clasificación)

Accuracy

$$\text{Accuracy} = \frac{\text{Aciertos}}{\text{Total}}$$

- Mide la proporción de predicciones correctas
- Ideal para clases balanceadas
- Ejemplo:
 - Reales: [0, 1, 0, 1]
 - Predicciones: [0, 1, 1, 1]
 - Accuracy: $\frac{3}{4} = 0.75$ (75%)

Métricas de desempeño: Ejemplo de regresión

Altura	Peso
169.948447	?
173.865754	?
174.661475	?
170.597762	?

Métricas de desempeño: Ejemplo de regresión

Altura	Peso
169.948447	82.552060
173.865754	75.674023
174.661475	84.338528
170.597762	87.721204

MAE (Regresión)

MAE

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Error promedio absoluto
- Menos sensible a outliers que MSE
- Ejemplo:
 - Reales: [170, 180, 175] cm
 - Predicciones: [172, 177, 173] cm
 - MAE: $\frac{2+3+2}{3} \approx 2.33$ cm

Funciones de costo

Una **función de pérdida**, o **función de costo**, es una función que asigna un evento o los valores de una o más variables a un número real que representa intuitivamente algún *costo* asociado al evento. Un problema de optimización trata de minimizar una función de pérdida.

Un algoritmo de Machine Learning busca minimizar o maximizar esta función cambiando sus **parámetros internos**. Frecuentemente se usa el **descenso de gradiente** para este fin, por lo tanto, típicamente se requiere de una función de costo diferenciable o convexa.

- Regresión: MSE, RMSE, MAE.
- Clasificación: 0-1, binaria asimétrica, entropía cruzada, Hinge loss.

Diferencia entre función de costo y métrica de desempeño

Típicamente son funciones diferentes, bajo ciertas condiciones se puede usar la misma.

- Usando la función de costo como métrica de desempeño: puede ser confusa de interpretar.
- Usando la métrica de desempeño como función de costo: puede no ser posible si no es diferenciable o convexa.

Resumiendo

Un problema de Machine Learning consiste en los siguientes pasos:

- **Recopilación de datos:** Los datos deben ser suficientes y representativos del problema que se busca resolver.
- **Preprocesamiento:** Limpiar los datos para eliminar ruido, valores faltantes, valores atípicos, y los prepara para su uso en el modelo.
- **Selección del algoritmo.**
- **Entrenamiento del modelo:** Utiliza el conjunto de datos de entrenamiento para entrenar el modelo elegido. La mejora se rige usando la [función de costo](#).
- **Evaluación del modelo:** Evalúa el modelo utilizando el conjunto de datos de prueba. Esto se hace con la [métrica de rendimiento](#).
- **Implementación, Monitoreo y Mantenimiento.**