



Procesamiento de Lenguaje Natural

Representación vectorial de texto

Mauricio Toledo-Acosta
mauricio.toledo@unison.mx

Departamento de Matemáticas
Universidad de Sonora



Section 1

Introducción



3/22



Section 2

Modelo BOW



- ¿Cómo representamos texto de forma que un algoritmo pueda procesarlo?
- Los modelos matemáticos trabajan con números, no con palabras.

La idea central del modelo BoW (1962):

- Un documento se representa como un vector numérico.
- Cada posición del vector corresponde a una palabra del vocabulario.
- El valor indica cuántas veces aparece esa palabra en el documento.

“Es una bolsa donde echamos todas las palabras del documento, ignorando su orden”



La matriz term-document

Procesamiento
de Lenguaje
Natural

Introducción

Modelo BOW

Modelo
TF-IDF

La métrica
angular

Representaciones
basados en
redes
neuronales

- La Revolución Francesa fue un período de grandes **cambios** políticos y sociales en **Europa**.
- El Imperio Romano dominó gran parte de **Europa** durante siglos, expandiéndose por toda **Europa**.
- La paella es un plato tradicional de España que lleva **arroz**, mariscos y verduras.
- El sushi es una comida japonesa hecha con **arroz** y **pescado** crudo, acompañado de algas.

Texto	Europa	cambios	arroz	pescado
1	1	1	0	0
2	2	0	0	0
3	0	0	1	0
4	0	0	1	1

Visualización



El modelo BOW asigna a cada documento el vector correspondiente a la fila. El vector de cada palabra es su columna.

Visualización



Ventajas y Desventajas

Ventajas:

Desventajas:



- Las palabras muy comunes (“el”, “de”, “y”) dominan los vectores. No necesariamente las stopwords.
- Estas palabras aportan poco sobre el contenido real del documento.

- No todas las palabras son igual de importantes.
- Una palabra es relevante si aparece *mucho* en un documento pero aparece en *pocos* documentos del corpus.



La matriz TF-IDF

Procesamiento
de Lenguaje
Natural

Introducción

Modelo BOW

Modelo
TF-IDF

La métrica
angular

Representaciones
basados en
redes
neuronales

- La Revolución Francesa fue un período de grandes **cambios** políticos y sociales en **Europa**.
- El Imperio Romano dominó gran parte de **Europa** durante siglos, expandiéndose por toda **Europa**.
- La paella es un plato tradicional de España que lleva **arroz**, mariscos y verduras.
- El sushi es una comida japonesa hecha con **arroz** y **pescado** crudo, acompañado de algas.

Texto	Europa	cambios	arroz	pescado
1	0.043	0.301	0	0
2	0.043	0	0	0
3	0	0	0.090	0
4	0	0	0.060	0.301

Los valores TF-IDF ponderan la importancia de cada término según su frecuencia en el documento y su rareza en el corpus.





Ejemplo: *Europa* en Texto 2

Ejemplo: *arroz* en Texto 3



Ventajas y Desventajas

Procesamiento de Lenguaje Natural

Introducción

Modelo BOW

Modelo
TF-IDF

La métrica
angular

Representaciones
basados en
redes
neuronales

Ventajas:

- Mejora la representación al ponderar términos
- Reduce el impacto de términos muy frecuentes
- Identifica términos relevantes por documento
- Mejor rendimiento en recuperación de información
- Fácil de implementar y computacionalmente eficiente

Desventajas:

- No captura relaciones semánticas entre términos
- Matriz grande y *sparse*
- Sensible a la longitud del documento
- No resuelve problemas de polisemia o sinonimia
- Depende de la calidad del corpus de entrenamiento



Section 4

La métrica angular



$$d_{\theta}(u, v) = \arccos \left(\frac{u \cdot v}{|u| \cdot |v|} \right)$$

$$\text{sim}(u, v) = \frac{u \cdot v}{|u| \cdot |v|}$$



¿Cómo medir la distancia entre documentos?

- Doc 0: “buen hotel, economico, muy recomendable hotel, mi hotel favorito”
- Doc 1: “buen hotel, economico”
- Doc 2: “buen automovil economico”

Trabajo en clase

- 1 Representa cada documento como vector BOW, es decir, construye la matriz termino-documento.
- 2 ¿Cuál debería ser el documento más similar a Doc 1 semánticamente?
- 3 Encuentra el documento más similar a Doc 1 de dos maneras:
 - Usa la métrica euclidiana
 - Usa la métrica angular



Conclusión

Procesamiento de Lenguaje Natural

Introducción

Modelo BOW

Modelo TF-IDF

La métrica angular

Representaciones basados en redes neuronales

La similitud coseno, o métrica angular, suele ser la métrica ideal para medir distancias entre representaciones de documentos (incluso en modelos basados en redes neuronales).

Dos documentos son similares si sus vectores apuntan en una dirección similar, sin importar su longitud. La distancia coseno se centra en el contenido de palabras. De esta forma, ignora la longitud del documento y captura mejor la similitud temática.



Section 5

Representaciones basados en redes neuronales



Limitaciones de modelos clásicos

Procesamiento de Lenguaje Natural

Introducción

Modelo BOW

Modelo TF-IDF

La métrica angular

Representaciones basados en redes neuronales

- Los vectores obtenidos mediante frecuencias, como BOW o Tf-IDf, tienen muchos ceros y son de dimensión muy alta.
- Promediar vectores de palabras, como Word2Vec (Google) o GloVe (Stanford), para representar documentos tiende a diluir la información semántica.

