

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures
Modules

Aprendizaje Profundo

Redes Neuronales MLP

Mauricio Toledo-Acosta

Departamento de Matemáticas
Universidad de Sonora



¿Dónde encontramos Deep Learning en la vida real?

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

- **Asistentes virtuales**:
  - LLMs: DeepSeek, Qwen, ChatGPT, Claude, etc.
  - Siri, Alexa (reconocimiento de voz y respuestas).
- **Redes sociales y fotos**:
  - Etiquetado automático de personas en fotos.
  - Filtros de cámara.
  - Sistemas de recomendación.
- **Seguridad y tecnología**:
  - Reconocimiento facial.
  - Detección de fraudes en tarjetas de crédito.
- **Transporte y mapas**:
  - Recomendación de rutas en Google Maps/Waze.
  - Coches autónomos.
- **Salud**:
  - Diagnóstico médico asistido.
  - Wearables.



El Aprendizaje Automático

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules

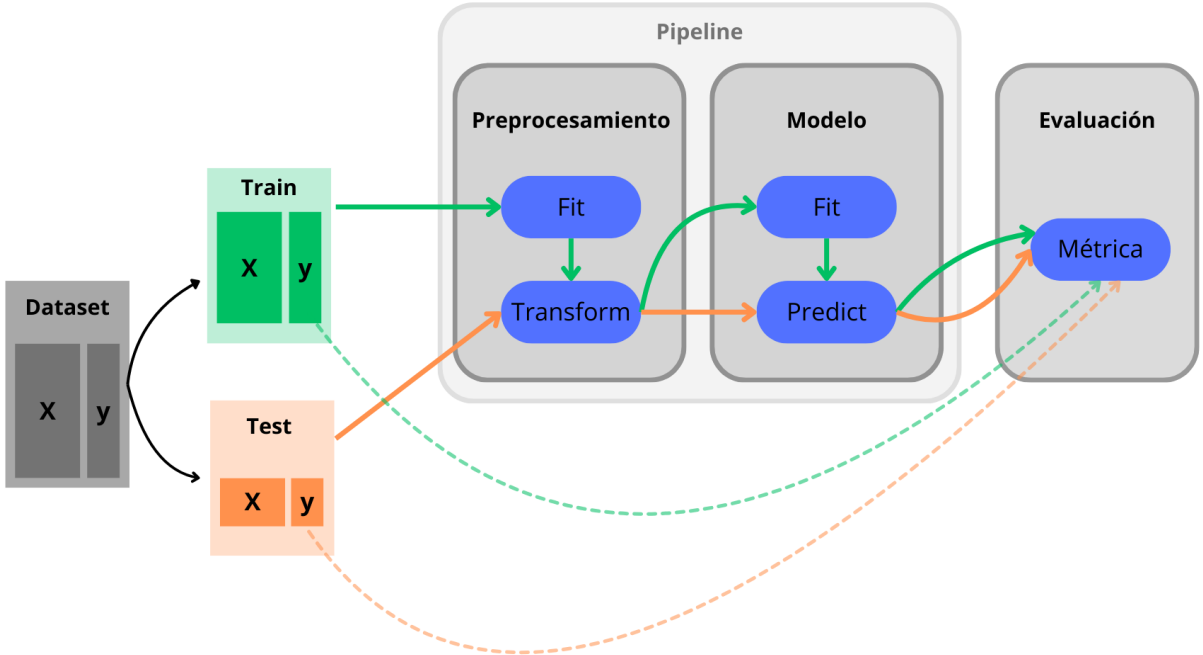




Table of Contents

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures
Modules

1 Redes Neuronales
- Back Propagation
- Loss Functions
- Optimizers
- Ejemplo 1 de Backpropagation
- Ejemplo 2 de Backpropagation
- Otras Arquitecturas
- Architectures

2 Modules

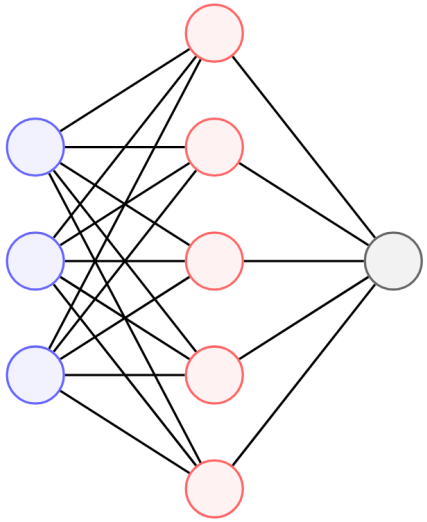


¿Qué es una red neuronal?

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules



Una red neuronal es una función es un modelo de Machine Learning que se compone de una sucesión de capas de neuronas. Se asemeja al cerebro en dos aspectos:

1. El conocimiento es adquirido por la red a través de un proceso de aprendizaje.
2. Las fuerzas de conexión entre neuronas, conocidas como pesos sinápticos, se utilizan para almacenar el conocimiento.

S. Haykin (1994), Neural Networks, MacMillan



Entrenamiento de una red neuronal

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

En estos problemas a modelar tenemos un conjunto de entradas $x = \{x_1, \ldots, x_n\} \in \mathbb{R}^D$ y algún proceso que resulta en un conjunto correspondiente de salidas $y = (y_1, \ldots, y_m) \in \mathbb{R}^m$.
La hipótesis es que el proceso está dado por alguna función matemática, es decir,

$$y = G(x)$$

para alguna función G que puede ser muy complicada.



Entrenamiento de una red neuronal

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

Para aproximar la función G elegimos una función *candidata* F de alguna familia parametrizada de funciones. Encontramos los parámetros de F usando un conjunto dado de ejemplos, es decir, algunas entradas x y sus respectivas salidas $y = G(x)$.

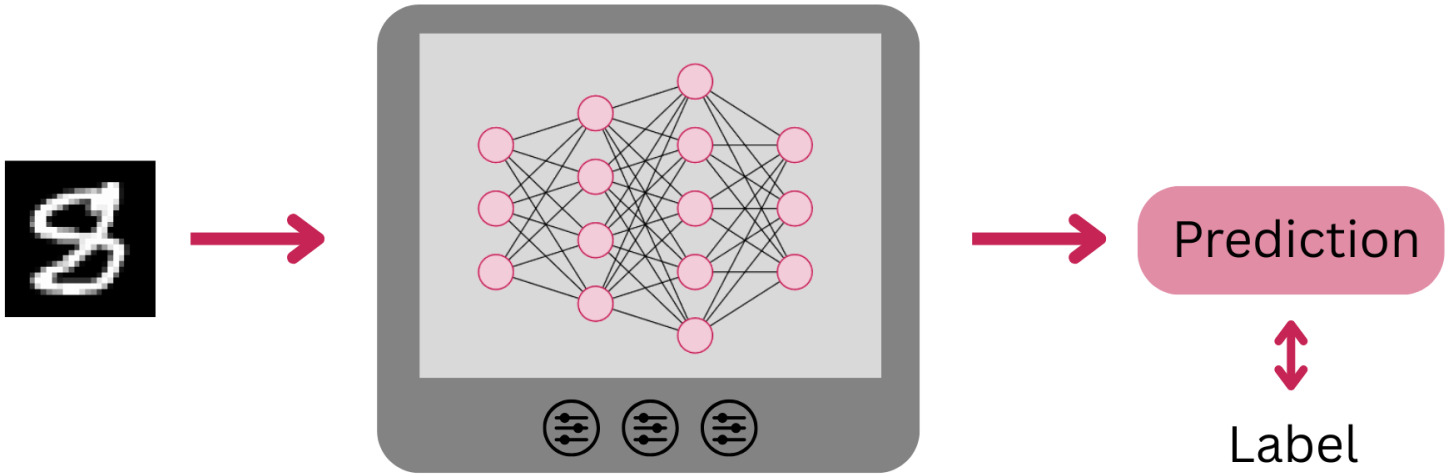
Entrenar una red neuronal significa encontrar estos parámetros. El entrenamiento se compone de dos pasos:

1. **Feed Forward**: Producir salidas con F usando algunos parámetros.
2. **Back Propagation**: Ajustar los parámetros midiendo el error de las salidas contra las salidas reales.



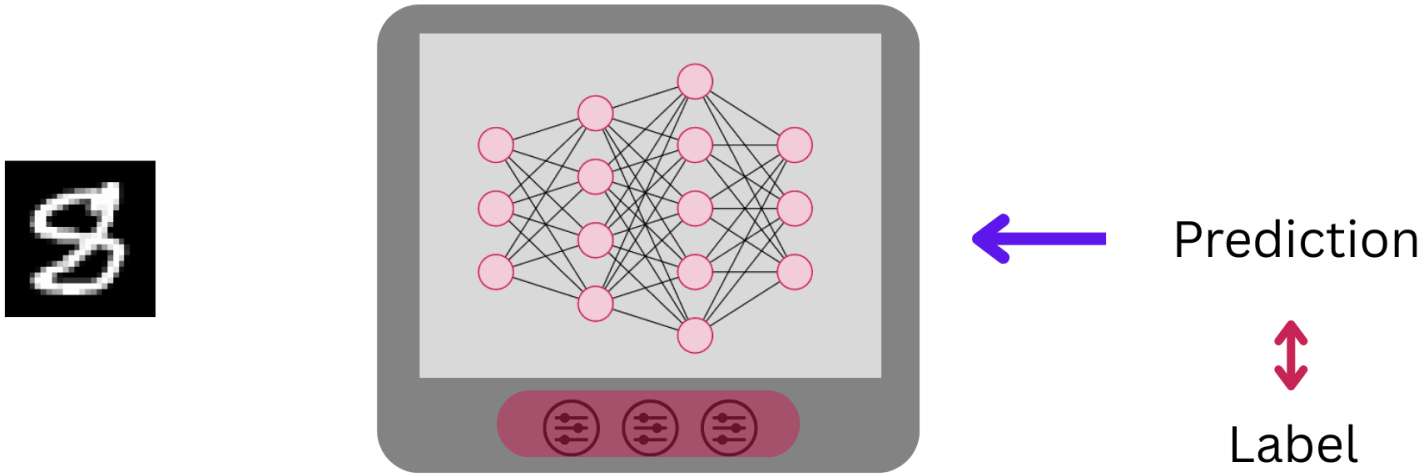
1. Feed Forward

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures
Modules



2. Back Propagation

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures
Modules





El perceptron: una neurona

Rosenblatt, 1957

Un perceptrón o neurona es una función $P : \mathbb{R}^D \to \mathbb{R}$ dada por

$$P(x_1, ..., x_D) = f\left(w_0 + \sum_{i=1}^{D} w_i x_i\right)$$

donde $f : \mathbb{R} \to \mathbb{R}$ es continua y no lineal, llamada función de activación y $w_0, ..., w_D \in \mathbb{R}$ son pesos. A w_0 se le llama sesgo o bias.

Podemos reescribir como

$$P(x_1, ..., x_D) = f\left(\begin{pmatrix} w_0 & w_1 & ... & w_D \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ ... \\ x_D \end{pmatrix}\right)$$



Funciones de activación

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules

- Sigmoide:

$$f(x) = \frac{1}{1 + e^{-x}}$$

- Tangente hiperbólica:

$$f(x) = \tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

- ReLU (Rectified Linear Unit):

$$f(x) = \begin{cases} x, & \text{si } x \geq 0, \\ 0, & \text{si } x < 0. \end{cases}$$

- Softmax (para un vector $\mathbf{x} = (x_1, \ldots, x_K) \in \mathbb{R}^K$):

$$\text{Softmax}(\mathbf{x})_i = \frac{e^{x_i}}{\sum_{j=1}^{K} e^{x_j}} \quad \text{para } i = 1, \ldots, K$$



Capas de neuronas

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

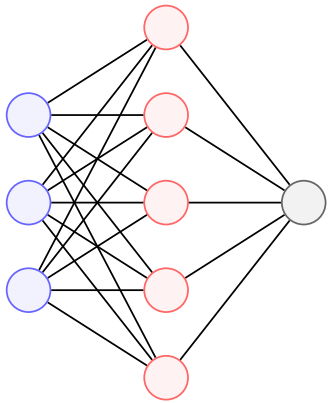
Modules

Una capa de m neuronas es una función $P : \mathbb{R}^D \to \mathbb{R}^m$:

$$P(x_1, ..., x_D) = f\left(W \cdot \tilde{x}\right)$$

$$= f\left(\begin{pmatrix} w_{1,0} & w_{1,1} & \dots & w_{1,D} \\ w_{2,0} & w_{2,1} & \dots & w_{2,D} \\ \dots & \dots & \dots & \dots \\ w_{m,0} & w_{m,1} & \dots & w_{m,D} \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ \dots \\ x_D \end{pmatrix}\right)$$

$W \in \mathcal{M}_{m\times(D+1)}(\mathbb{R})$ son los pesos $w_{i,j}$ y sesgos $w_{i,0}$. La función $f : \mathbb{R}^m \to \mathbb{R}^m$ aplica la misma función de activación en cada una de las m componentes de $W \cdot \tilde{x}^T$.





Varias capas de neuronas

Aprendizaje Profundo

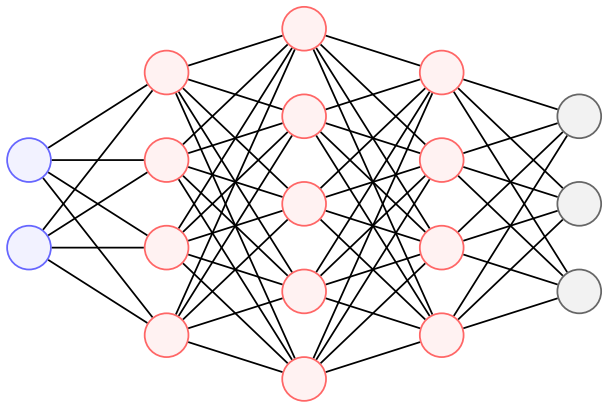
Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

Podemos apilar L capas de $m_1, \ldots, m_L$ neuronas respectivamente:

1. La primera capa oculta es una función $P_1 : \mathbb{R}^{m_0} \to \mathbb{R}^{m_1}$ donde $m_0 = D$.
2. Continuamos de forma análoga hasta llegar a la L-ésima capa oculta, que es una función $P_L : \mathbb{R}^{m_{L-1}} \to \mathbb{R}^{m_L}$.

Las capas $P_1, ..., P_L$ se denominan capas ocultas. Apilamos una capa de salida $P_{L+1} : \mathbb{R}^{m_L} \to \mathbb{R}^{m_{L+1}}$. Este ensamble de capas es una red MultiLayer Perceptron (MLP) con L capas ocultas y arquitectura $(m_0 = D, m_1, \ldots, m_L, m_{L+1})$.





Teoremas Universales de Aproximación

Sea $\sigma \in C(\mathbb{R})$ una función de activación. Definimos la clase de funciones

$$\mathcal{M}(\sigma) = \text{span}\left\{x \mapsto \sigma(w \cdot x - \theta) \,|\, \theta \in \mathbb{R}, w \in \mathbb{R}^n\right\}$$

Teorema Universal de Aproximación

Sea $\sigma \in C(\mathbb{R})$. Entonces $\mathcal{M}(\sigma)$ es densa en $C(\mathbb{R}^n)$, en la topología de convergencia uniforme en compactos, si y solo si σ no es un polinomio.

Es decir, siempre podemos encontrar una red neuronal que aproxime tanto como queramos a una función continua $f : \mathbb{R}^n \to \mathbb{R}$ dada, usando funciones de activación no polinomiales.



¿Qué pasa si la función de activación es polinomial?

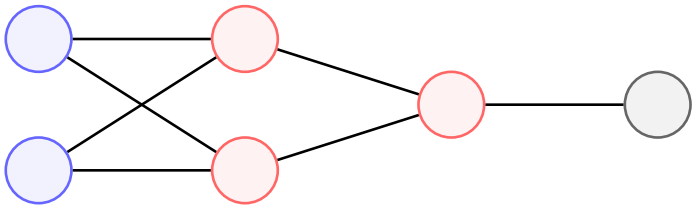
Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

La flexibilidad de una red MLP está dada por las funciones de activiación no lineales. Tomemos dos capas de 1 neurona con activación lineal. Si $P_1(x_1, x_2) = w_0^{(1)} + w_1^{(1)} x_1 + w_2^{(1)} x_2$ y $P_2(z) = w_0^{(2)} + w_1^{(2)} z$ entonces

$$P_2 \circ P_1(x_1, x_2) = \begin{pmatrix} w_0^{(2)} + w_1^{(2)} w_0^{(1)} \\ w_1^{(2)} w_1^{(1)} \\ w_1^{(2)} w_2^{(1)} \end{pmatrix}^T \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix}$$





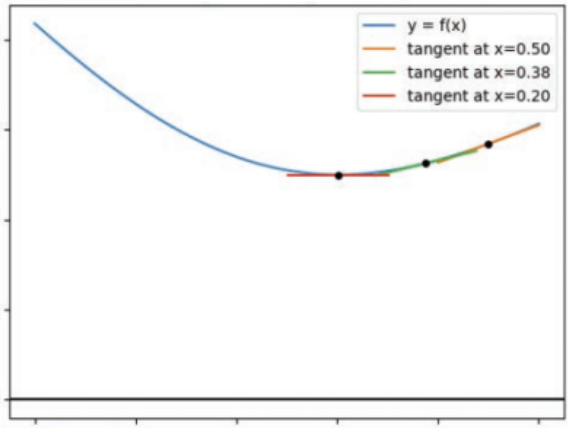
¿Cómo encontramos el mínimo de una función?

- Sea $f(x)$ una función, queremos encontrar el mínimo de f.



¿Cómo encontramos el mínimo de una función?

- Sea $f(x)$ una función, queremos encontrar el mínimo de f.
- La derivada en el punto x que minimiza el valor de f es 0.





Descenso de gradiente

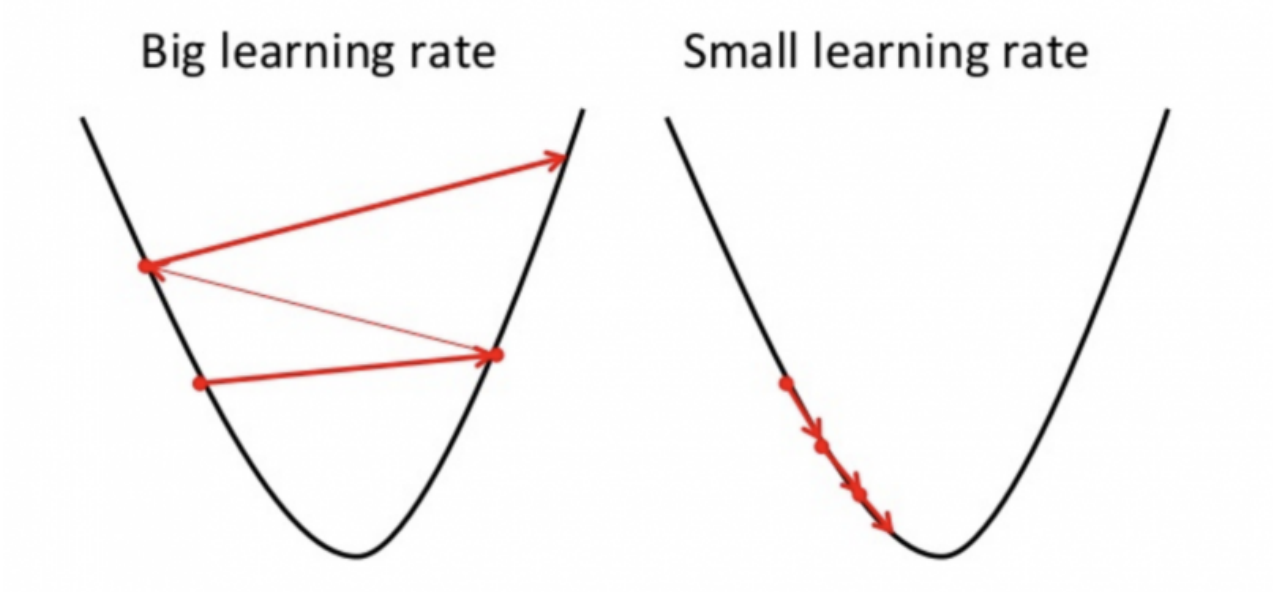
- A partir de un valor inicial x queremos encontrar un valor que minimiza f.
- El signo de $f'(x)$ nos indica la dirección en la cual *mover* x para reducir el valor de $f(x)$.
- La magnitud de $f'(x)$ nos indica que tanto ajustar x. Usamos un peso η, llamado learning rate,

$$x_{n+1} = x_n - \eta f'(x_n).$$

- Si η es muy grande, el método puede *pasarse* de la solución y no converger.
- El algoritmo no garantiza encontrar el mínimo global, puede quedarse atorado en un mínimo local.



Learning Rate





El caso de dimensión alta

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules

- Consideremos la función $f(x_0, x_1)$.

El caso de dimensión alta

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

Ejemplo 1 de Backpropagation

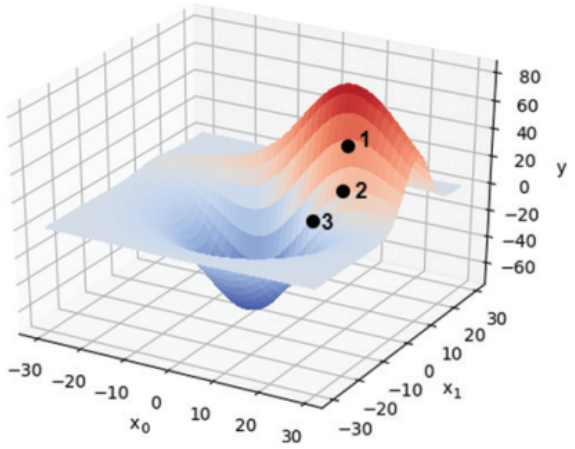
Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules

- Consideremos la función $f(x_0, x_1)$.
- El gradiente es un vector que consta de las derivadas e indica la dirección en el espacio de features en la que se produce el ascenso más pronunciado en el valor de f.





El caso de dimensión alta

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

Ejemplo 1 de Backpropagation

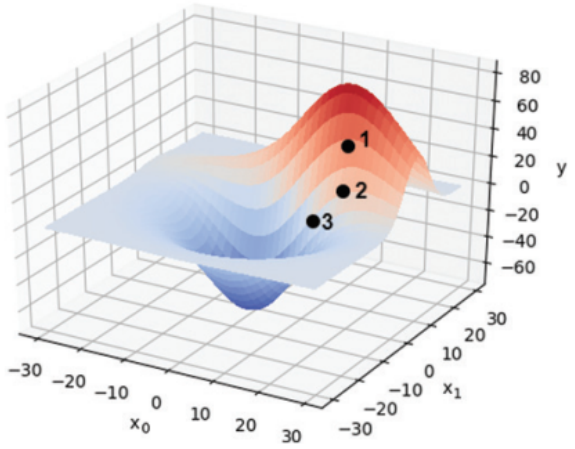
Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules

- Consideremos la función $f(x_0, x_1)$.
- El gradiente es un vector que consta de las derivadas e indica la dirección en el espacio de features en la que se produce el ascenso más pronunciado en el valor de f.



- Si estamos en el punto $\mathbf{x_n} = \left(x_0^{(n)}, x_1^{(n)}\right)$ y queremos minimizar f, ajustamos el punto de la siguiente forma

$$\mathbf{x_{n+1}} = \mathbf{x_n} - \eta \nabla f(\mathbf{x_n})$$



Gradient-based Learning

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

Al aplicar descenso de gradiente a nuestra red neuronal, consideramos las features **x** como constantes, el objetivo es encontrar los pesos **w** de tal forma que minimicemos el error.

- ¿Qué función queremos minimizar? Una función de perdida.



Gradient-based Learning

Al aplicar descenso de gradiente a nuestra red neuronal, consideramos las features **x** como constantes, el objetivo es encontrar los pesos **w** de tal forma que minimicemos el error.

- ¿Qué función queremos minimizar? Una función de perdida.

- En el contexto de optimización, la función que evalua una solución candidata se le llama función objectivo. En las redes neuronales, la función objetivo se le llama función costo o perdida (loss function).



Gradient-based Learning

- In the case of the Perceptron, the loss function is given by

$$L^{(0/1)}(\mathbf{w}) = (y_i - \text{sign}\langle \mathbf{w}, \mathbf{x}_i \rangle)^2$$



Gradient-based Learning

- In the case of the Perceptron, the loss function is given by

$$L^{(0/1)}(\mathbf{w}) = \frac{1}{2}(y_i - \text{sign}\langle \mathbf{w}, \mathbf{x}_i \rangle)^2 = 1 - y_i \text{sign}\langle \mathbf{w}, \mathbf{x}_i \rangle$$

- This function is not smooth, we use the smooth surrogate loss function

$$L(\mathbf{w}) = \max\{-y_i \text{sign}\langle \mathbf{w}, \mathbf{x}_i \rangle, 0\}.$$



Gradient-based Learning

- In the case of the Perceptron, the loss function is given by
- This function is not smooth, we use the smooth surrogate loss function

$$L(\mathbf{w}) = \max\{-y_i \text{sign}\langle \mathbf{w}, \mathbf{x}_i \rangle, 0\}.$$

- Applying gradient descent

$$\begin{aligned} \mathbf{w}_{n+1} &= \mathbf{w}_n - \eta \nabla L(\mathbf{w}) \\ &= \begin{cases} \mathbf{w}_n + \eta y_i \mathbf{x}_i, & \text{well classified} \\ \mathbf{w}_n, & \text{misclassified} \end{cases} \end{aligned}$$



Loss Functions

Other examples of loss functions

- Keras Losses



Loss Functions: MSE

Mean Square Error (MSE)

$$L(y, t) = (t - y)^2.$$

- L2 loss.



Loss Functions: MSE

Mean Square Error (MSE)

$$L(y, t) = (t - y)^2.$$

- L2 loss.
- Good for regression tasks.



Loss Functions: MSE

Mean Square Error (MSE)

$$L(y, t) = (t - y)^2.$$

- L2 loss.
- Good for regression tasks.
- Trivial derivative for gradient descent.



Loss Functions: MAE

Mean Absolute Error (MAE)

$$L = |t - y|.$$

- L1 loss.
- More robust to outliers than mse.
- Good for regression tasks.
- Discontinuity in its derivative.



Loss Functions: Hinge

Hinge Loss

$$L = \max\{-y_i \hat{y}_i, 0\}.$$

- Used in SVMs and Perceptron.
- Penalizes errors, but also correct predictions of low confidence (probabilities).
- Good for binary classification tasks.



Loss Functions: Categorical cross entropy

Categorical cross entropy

$$L = \sum_{i}^{n} y_i \log\left(\hat{y}_i\right).$$

- Good for multi-class classification problems.
- Considers y to be a one-hot encoding vector in n classes.



Optimizers: Gradient Descent

Gradient descent is the most basic and intuitive optimization algorithm. Gradient descent is a first-order optimization algorithm which is dependent on the first order derivative of a loss function.

Advantages:

- Easy to implement.
- Easy to understand.



Optimizers: Gradient Descent

Gradient descent is the most basic and intuitive optimization algorithm. Gradient descent is a first-order optimization algorithm which is dependent on the first order derivative of a loss function.

Advantages:

- Easy to implement.
- Easy to understand.

Disadvantages:

- May get trap at local minima.
- Weights are changed after calculating gradient on the whole dataset (or batch). May take a long time to converge.
- Requires large memory to calculate gradient on the whole dataset (or batch).



Optimizers

We can use other optimizers:

- Gradient Descent
- Stochastic Gradient Descent
- Stochastic Gradient Descent with momentum
- Mini-Batch Gradient Descent
- Adagrad
- RMSProp
- AdaDelta
- Adam

▸ Keras Optimizers



Different Optimizers

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

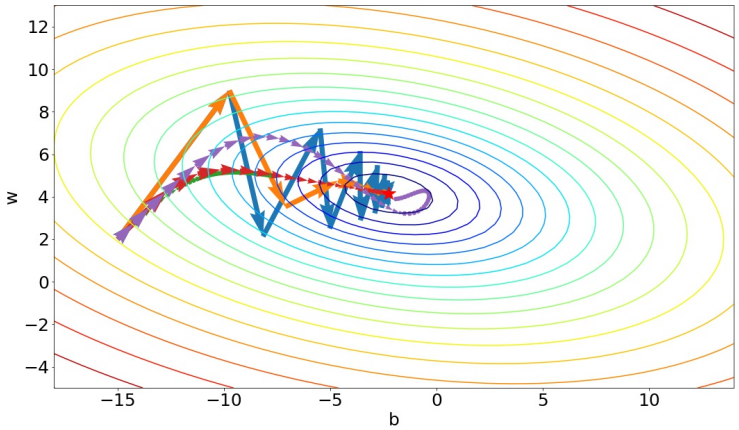
Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules



Visualizaciones, Several optimizers

Ejemplo 1: Back-propagation

Configuración: 1 neurona (sin sesgo por simplicidad). Entrada x, peso w, salida $a = \sigma(wx)$.
Activación: Sigmoide $\sigma(z) = \frac{1}{1+e^{-z}}$ **Pérdida (MSE):** $E = \frac{1}{2}(a-y)^2$
Valores iniciales: $x = 1$, $y = 1$ (objetivo), $w = 0$, Tasa de aprendizaje $\alpha = 1$.

1. Fórmulas (Regla de la Cadena)

$$\frac{\partial E}{\partial w} = \frac{\partial E}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$
$$= (a-y) \cdot \underbrace{[\sigma(z)(1-\sigma(z))]}_{\text{Derivada sigmoide}} \cdot x$$
$$= (a-y) \cdot [a(1-a)] \cdot x$$

Regla de actualización:

$$w_{nueva} = w - \alpha \frac{\partial E}{\partial w}$$

2. Cálculo Numérico

- **Feed Forward:**
  $z = wx = (0)(1) = 0$
  $a = \sigma(0) = 0.5$
- **Backpropagation:**
  $$\frac{\partial E}{\partial w} = (0.5-1) \cdot [0.5(1-0.5)] \cdot 1$$
  $$= (-0.5) \cdot (0.25) \cdot 1$$
  $$= -0.125$$
- **Actualización del peso:**
  $$w_{nueva} = 0 - (1)(-0.125)$$
  $$w_{nueva} = \mathbf{0.125}$$



Ejemplo 2: Back-propagation

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

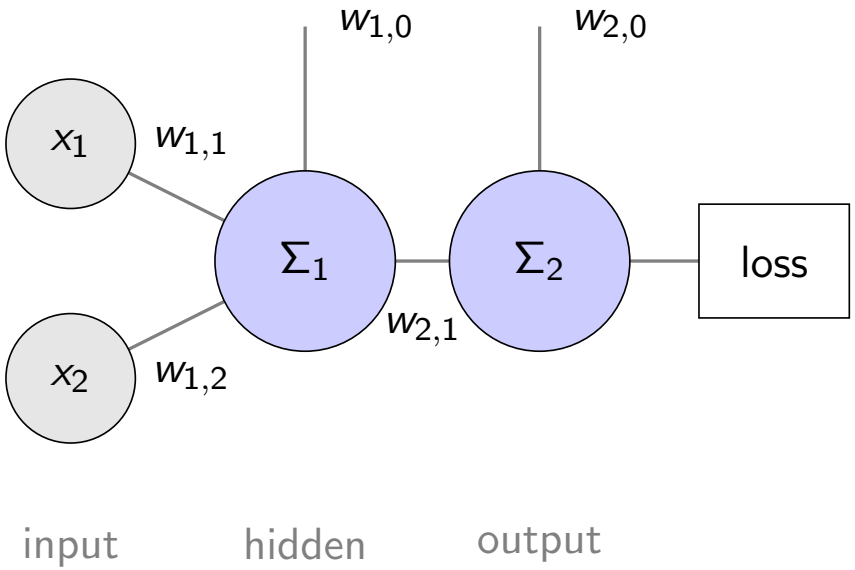
Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules



This neural network implements

$$f = S\left(w_{2,0} + w_{2,1}\tanh(w_{1,0} + w_{1,1}x_1 + w_{1,2}x_2)\right)$$

We use the MSE loss:

$$e(f) = \frac{1}{2}(y - f)^2.$$



Example: Back-propagation

- The error is given by

$$e(\mathbf{w}) = \frac{1}{2}\left(y - S\left(w_{2,0} + w_{2,1}\tanh(w_{1,0} + w_{1,1}x_1 + w_{1,2}x_2)\right)\right)^2$$

where $\mathbf{w} = (w_{1,0}, w_{1,1}, w_{1,2}, w_{2,0}, w_{2,1})$

- We write it as:

$$\begin{aligned} e(f) &= \frac{1}{2}(y - f)^2 \\ f(z_f) &= S(z_f) \\ z_f(w_{2,0}, w_{2,1}, g) &= w_{2,0} + w_{2,1}g \\ g(z_g) &= \tanh(z_g) \\ z_g(w_{1,0}, w_{1,1}, w_{1,2}) &= w_{1,0} + w_{1,1}x_1 + w_{1,2}x_2 \end{aligned}$$



Example: Back-propagation

Compute the partial derivatives

$$\frac{\partial}{\partial w_{2,0}} e = -(y - f) S'(z_f)$$

$$\frac{\partial}{\partial w_{2,1}} e = -(y - f) S'(z_f) g$$

$$\frac{\partial}{\partial w_{1,0}} e = -(y - f) S'(z_f) w_{2,1} \tanh'(z_g)$$

$$\frac{\partial}{\partial w_{1,1}} e = -(y - f) S'(z_f) w_{2,1} \tanh'(z_g) x_1$$

$$\frac{\partial}{\partial w_{1,2}} e = -(y - f) S'(z_f) w_{2,1} \tanh'(z_g) x_2$$



Example: Back-propagation

Finally, we update the weights, via gradient descent

$$w_{2,0} \leftarrow w_{2,0} - \eta \frac{\partial e}{\partial w_{2,0}}$$

$$w_{2,1} \leftarrow w_{2,1} - \eta \frac{\partial e}{\partial w_{2,1}}$$

$$w_{1,0} \leftarrow w_{1,0} - \eta \frac{\partial e}{\partial w_{1,0}}$$

$$w_{1,1} \leftarrow w_{1,1} - \eta \frac{\partial e}{\partial w_{1,1}}$$

$$w_{1,2} \leftarrow w_{1,2} - \eta \frac{\partial e}{\partial w_{1,2}}$$



Algunas arquitecturas

Algunos tipos de arquitecturas de redes neuronales:

- Perceptrones Multicapa (MLP).
- Redes Convolucionales (CNN).
- Autoencoders y Variational Autoenconders.
- Long short-term memory (LSTM) y Redes Recurrentes (RNN).
- Generative adversarial network (GAN).
- Self-Organizing Map (SOM).
- Transformadores: GPT, BERT, DeepSeek, Claude
- Redes de Difusión (Diffusion Models)
- Redes Siamesas (Siamese Networks)
- Redes Neuronales de Grafos (GNN - Graph Neural Networks)



Elementos de una red neuronal

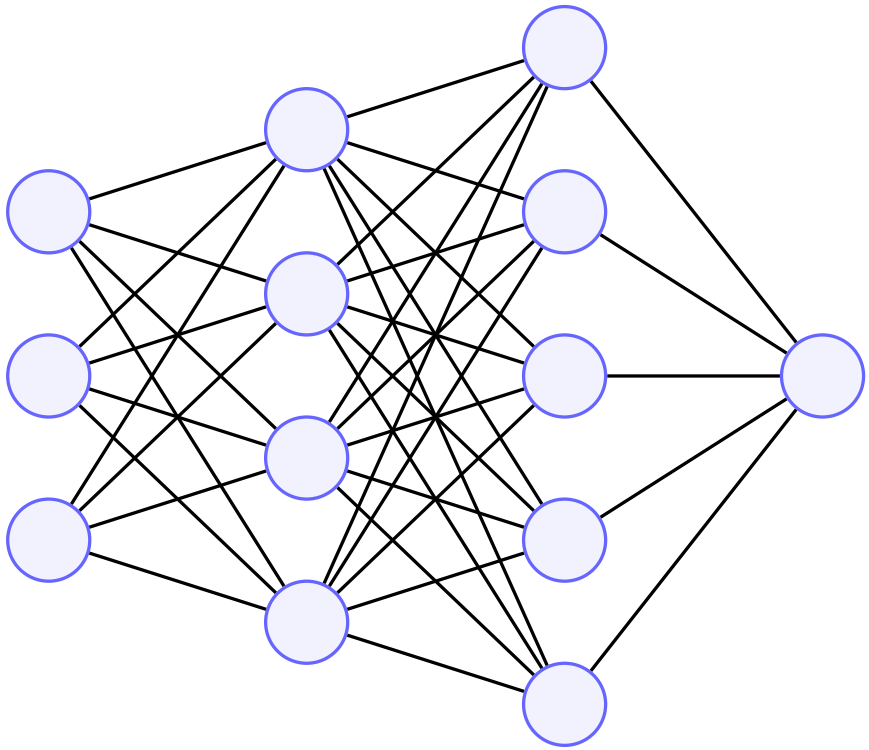
Los elementos necesarios para definir una red neuronal son:

- Capa de entrada adaptada al número de features.
- Capas ocultas, especificando el número de neuronas y la función de activación en cada capa ▸ Keras Layers.
- Función de activación ▸ Keras Activation Functions.
- Optimizador ▸ Keras Optimizers.
- Función de perdida ▸ Keras Losses.
- Métrica de rendimiento ▸ Keras Metrics.



Regression

Si tenemos tres variables independientes y una variable dependiente

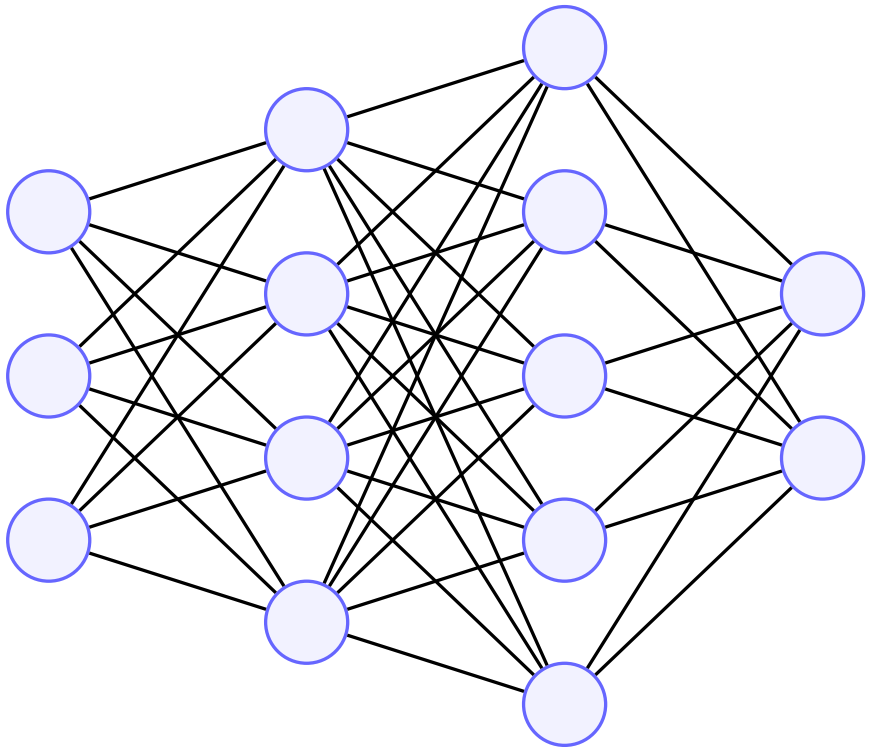


La función de activación en la capa de salida es *usualmente* `None` (la función identidad).



Multivariate Regression

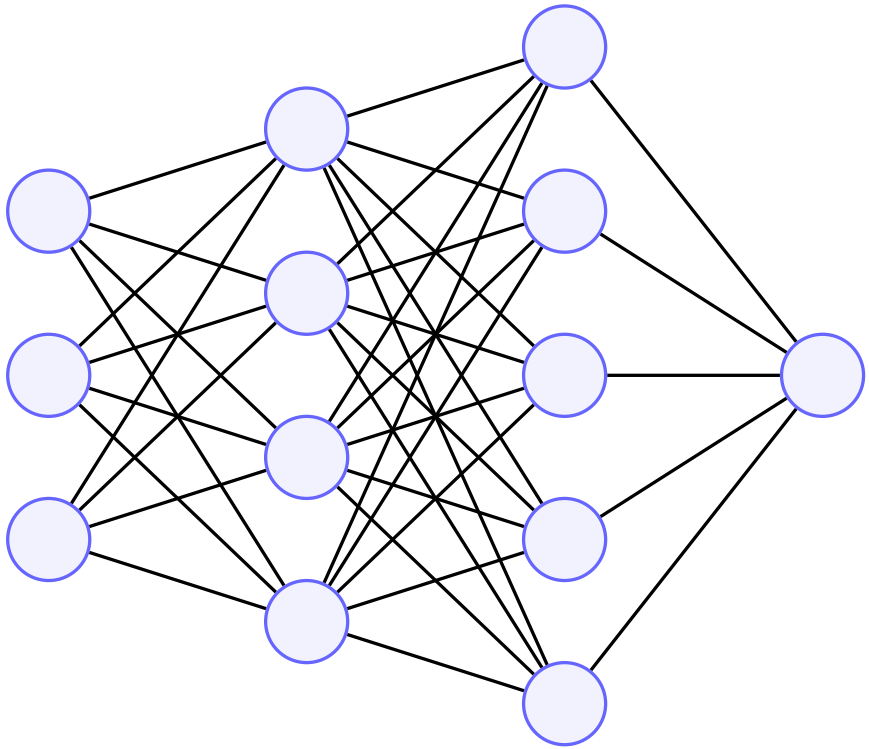
If we have three independent variables and two dependent variable



La función de activación en la capa de salida es *usualmente* `None` (la función identidad).

Binary Classification

If we have three independent variables and two classes



La función de activación en la capa de salida es la sigmoide

$$\sigma(x) = \frac{1}{1 + e^{-x}} \in (0, 1)$$



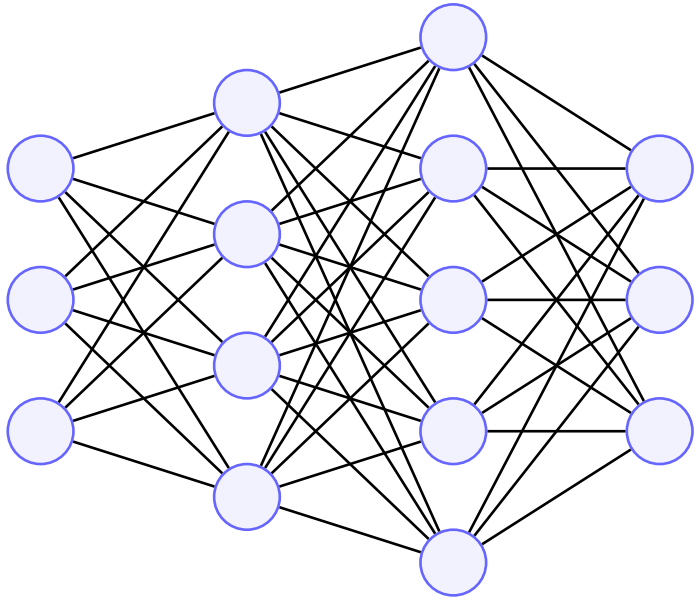
Multi-class Classification

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules

Si tenemos tres, o más, clases



La función de activación en la capa de salida es softmax

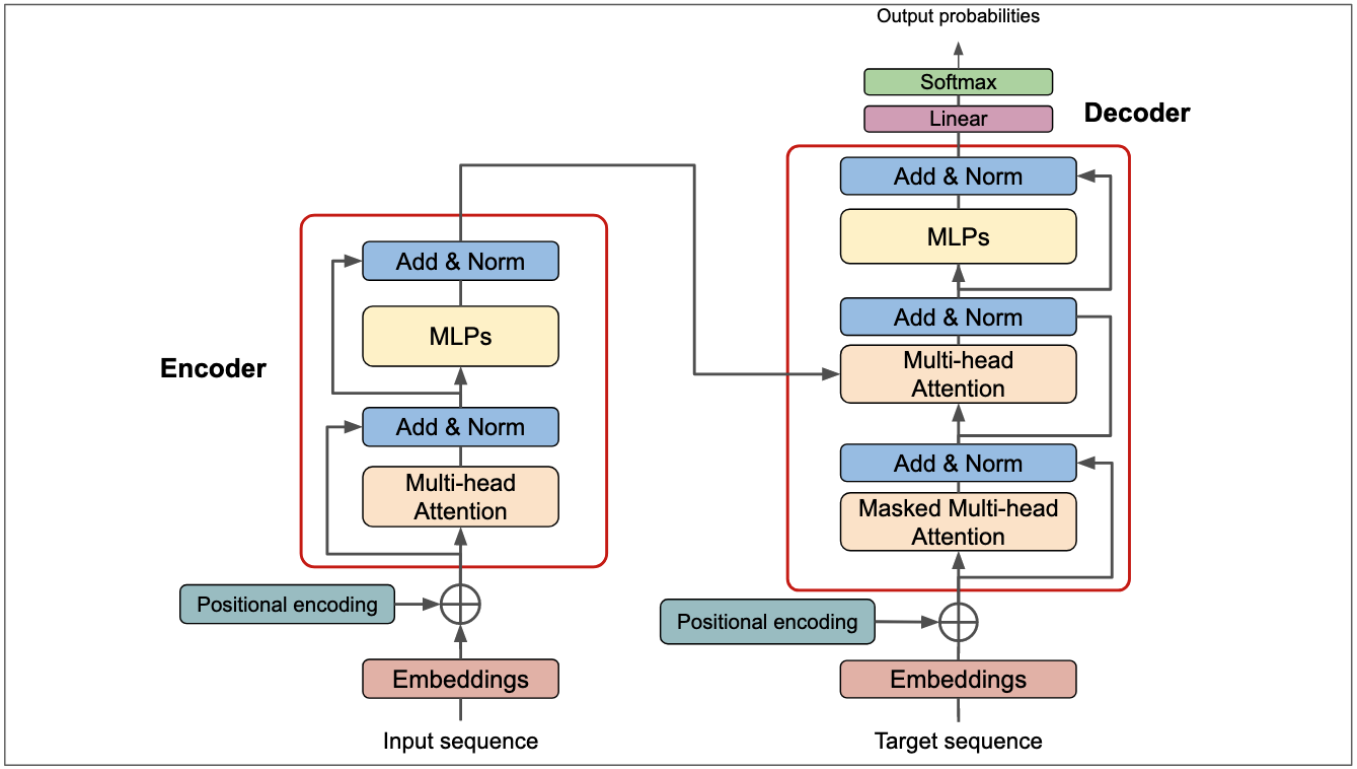
$$\sigma\left(j;\left(x_1,...,x_n\right)\right)=\frac{e^{x_j}}{\sum_{i=1}^{n}e^{x_i}}\in(0,1)$$

Transformadores: Arquitectura

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules



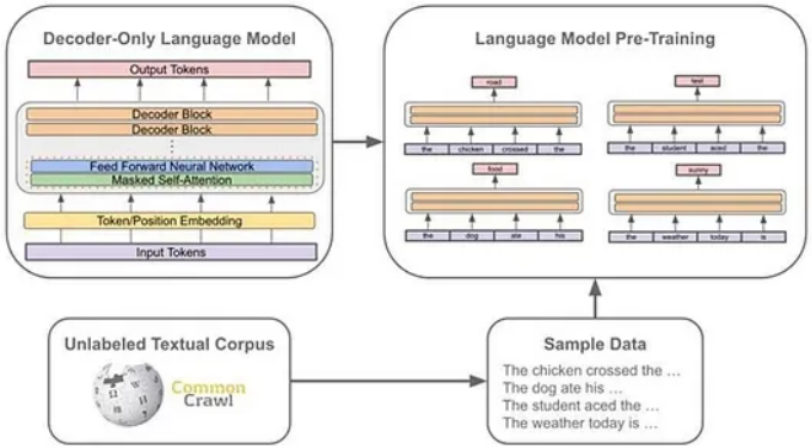
Entrenamiento explicado

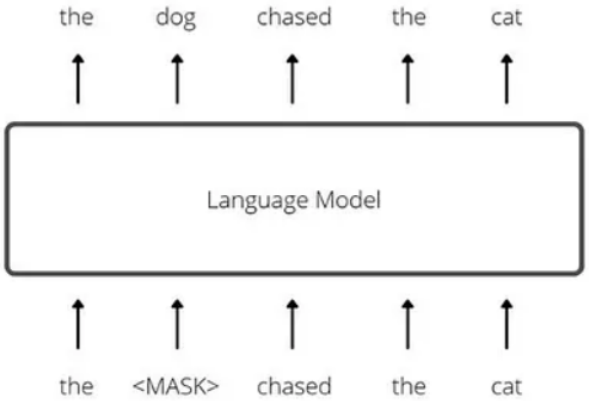
Transformadores: Entrenamiento de un LLM

Aprendizaje Profundo

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures

Modules





Entrenamiento explicado



Table of Contents

Redes Neuronales
Back Propagation
Loss Functions
Optimizers
Ejemplo 1 de Backpropagation
Ejemplo 2 de Backpropagation
Otras Arquitecturas
Architectures
Modules

1 Redes Neuronales
- Back Propagation
- Loss Functions
- Optimizers
- Ejemplo 1 de Backpropagation
- Ejemplo 2 de Backpropagation
- Otras Arquitecturas
- Architectures

2 Modules



Deep Learning Libraries



Tensorflow



Pytorch



Keras, Tensorflow and Pytorch

Aprendizaje Profundo

Redes Neuronales

Back Propagation

Loss Functions

Optimizers

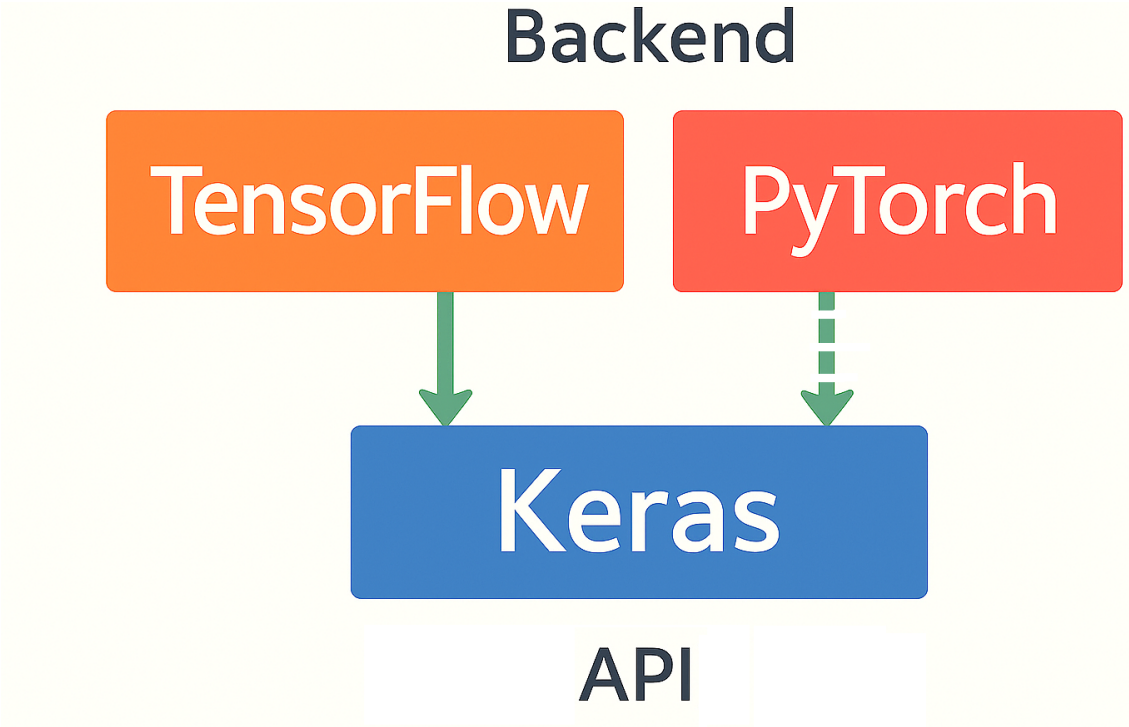
Ejemplo 1 de Backpropagation

Ejemplo 2 de Backpropagation

Otras Arquitecturas

Architectures

Modules





Comparación de los frameworks


```keras
from keras.models import Sequential
from keras.layers import Dense, Flatten

model = Sequential([
    Flatten(input_shape=(28, 28)),
    Dense(8, activation='relu'),
    Dense(10, activation='softmax')
])
```

Keras

```tensorflow
import tensorflow as tf

# 1. Definir variables (pesos y biases)
W1 = tf.Variable(tf.random.normal([28*28, 8]))
b1 = tf.Variable(tf.zeros([8]))
W2 = tf.Variable(tf.random.normal([8, 10]))
b2 = tf.Variable(tf.zeros([10]))

# 2. Función forward
def model(x):
    x = tf.reshape(x, [-1, 28*28])  # Flatten
    x = tf.nn.relu(tf.matmul(x, W1) + b1)
    return tf.nn.softmax(tf.matmul(x, W2) + b2)
```

TensorFlow Puro

```pytorch
import torch
import torch.nn as nn

class MLP(nn.Module):
    def __init__(self):
        super().__init__()
        self.flatten = nn.Flatten()
        self.dense1 = nn.Linear(28*28, 8)
        self.dense2 = nn.Linear(8, 10)

    def forward(self, x):
        x = self.flatten(x)
        x = torch.relu(self.dense1(x))
        return torch.softmax(self.dense2(x), dim=1)

model = MLP()
```

PyTorch